


شبکه‌های عصبی گرافی برای شطرنج

معرفی یک رویکرد نوین در مدل‌سازی شطرنج با استفاده از شبکه‌های عصبی گرافی (GNNs).

نویسنده مقاله: صالح الور | تحت نظارت: آسک پلات، والتر کاسترز



شبکه‌های عصبی گرافی برای شطرنج

ارائه توسط: رضا رنجبر

استاد محمدعلی علیمحمدی

دانشگاه ملی مهارت واحد استان مرکزی

این تحقیق کاربرد شبکه‌های عصبی گرافی (GNNs) را در مدل‌سازی شطرنج معرفی می‌کند. مدل GNN یک نمایش گرافی از صفحه شطرنج را به عنوان ورودی دریافت می‌کند که در آن خانه‌های شطرنج به عنوان گره‌ها و حرکات قانونی به عنوان یال‌ها به تصویر کشیده شده‌اند. این رویکرد به طور قابل توجهی بهتر از شبکه‌های باقیمانده سنتی (Residual Networks) در یادگیری سیاست و ارزش موقعیت‌های شطرنج عمل می‌کند.

پیش‌بینی سیاست به ویژه نسبت به روش‌های سنتی برتری دارد. این امر به توانایی مدل در یادگیری سیاست در امتداد یال‌ها، جذب دینامیک‌های رابطه‌ای موقعیت‌های شطرنج، و یادگیری بر روی یک فضای عملیاتی به طور قابل توجهی کاهش یافته نسبت داده می‌شود. این در تضاد شدید با روش‌های مبتنی بر آرایه سنتی است که بر روی فضای عملیاتی کامل ۴۶۷۲ حرکتی شطرنج یاد می‌گیرند.

مقدمه: چرا شبکه‌های عصبی گرافی (GNN)

این مقاله استفاده از شبکه‌های عصبی گرافی (GNNs)، به ویژه نوع شبکه توجه گرافی (GAT)، را برای مدل‌سازی شطرنج بررسی می‌کند. این حوزه به طور سنتی توسط شبکه‌های عصبی مبتنی بر آرایه مانند آنچه در آلفا زیرو (AlphaZero) و لایلا چس زیرو (Leela Chess Zero) با استفاده از شبکه‌های باقیمانده (ResNets) استفاده می‌شود، خدمت‌رسانی شده است.

شبکه‌های باقیمانده (ResNets)

معماری‌های سنتی مورد استفاده در شطرنج (AI مانند AlphaZero) که ورودی را به عنوان یک آرایه (تصویر) از صفحه شطرنج در نظر می‌گیرند و از لایه‌های کانولوشنال استفاده می‌کنند.

شبکه توجه گرافی (GAT)

یک نوع خاص از GNN که از مکانیسم‌های توجه برای وزن‌دهی اهمیت گره‌های همسایه استفاده می‌کند. این به مدل اجازه می‌دهد تا بر مهم‌ترین بخش‌های صفحه شطرنج تمرکز کند.


شبکه‌های عصبی گرافی (GNNs)

نوعی از شبکه‌های عصبی که مستقیماً بر روی ساختارهای گرافی کار می‌کنند. این شبکه‌ها برای مدل‌سازی روابط و وابستگی‌های بین گره‌ها (مانند خانه‌های شطرنج) عالی هستند.

هدف این مطالعه، تشخیص عناصر حیاتی برای نمایش گراف، پیشنهاد یک معماری GNN مؤثر برای تحلیل شطرنج و مقایسه عملکرد GNN با ResNets است.

روش‌ها: نمایش گراف و معماری دو-سر

ما از یک رمزگذاری استفاده می‌کنیم که صفحه شطرنج را به عنوان یک گراف به تصویر می‌کشد؛ با خانه‌ها به عنوان گره‌ها و حرکات بالقوه به عنوان یال‌ها. هر گره و یال شامل یک بردار ویژگی است که جزئیات خاص بازی را شرح می‌دهد.



مدل دو-سر GNN-graph


ما از یک مدل دو-سر (GNN-graph) استفاده می‌کنیم که شامل شبکه‌های GAT برای تولید دو تعبیه گره متمایز است:

سر سیاست (Policy Head)

دومین مجموعه از تعبیه‌های گره برای تشکیل تعبیه‌های حرکت از طریق الحاق تعبیه‌های گره منبع و هدف استفاده می‌شود. این به یک توزیع احتمال بر روی حرکات قانونی نگاشت می‌شود.


سر ارزش (Value Head)

اولین تعبیه گره جمع‌آوری شده و برای تخمین ارزش وضعیت تخته (احتمال برد) نگاشت می‌شود.




مقایسه مدل‌ها

برای مقایسه، دو مدل دیگر ایجاد شد تا عملکرد GNN-graph را در برابر روش‌های سنتی و هیبریدی ارزیابی کنیم:



ResNet (مدل پایه)

یک مدل پایه که نمایش مبتنی بر آرایه صفحه شطرنج را به سیاست و ارزش بازی در یک معماری شبیه به AlphaZero نگاهاشت می‌کند.



GNN-array (مدل هیبریدی)

مدلی که از GAT برای تعبیه تخته استفاده می‌کند اما سر ارزش و سیاست ResNet را منعکس می‌کند. این مدل قدرت GNN را با ساختار خروجی سنتی ترکیب می‌کند.



GNN-graph (مدل پیشنهادی)

مدل اصلی که از GATs استفاده می‌کند و تعبیه‌های حرکت را مستقیماً از طریق یال‌ها (الحاق گره‌های منبع و هدف) برای پیش‌بینی سیاست می‌سازد.



تعبیه (*Embedding*): در یادگیری عمیق، تعبیه به معنای تبدیل یک ورودی (مانند یک خانه شطرنج یا یک حرکت) به یک بردار عددی با ابعاد پایین‌تر است که معنای آن ورودی را در خود جای داده است.

بحث: دلایل برتری GNN

مسیر یادگیری پایدار

در طول فرآیند آموزش پایدارترین مسیر یادگیری را نشان داد GNN-graph

عملکرد در بازی رو در رو

در بازی‌های رو در رو نسبت به سایر مدل‌ها برتری دارد GNN-graph


انطباق‌پذیری

این مدل با موفقیت از طریق تنظیم دقیق، با مجموعه‌های داده کوچک و خاص بازیکن سازگار می‌شود.

استراتژی پیشنهادی برای ساخت سیاست، دلیل اصلی عملکرد برتر مدل مبتنی بر GNN نسبت به ResNet است.

نتایج و بحث: برتری GNN-graph

ما بهینه‌سازی ابرپارامتر را انجام دادیم که یک پیکربندی GNN مؤثر برای مدل‌سازی شطرنج را آشکار کرد. ابعاد پنهان و اندازه‌های تعبیه توجه به طور قابل توجهی در عملکرد نقش داشتند. آموزش با استفاده از مجموعه داده‌ای شامل ۱۳۵ هزار بازی استاد بزرگ و ۱۱ میلیون موقعیت تولید شده به صورت تصادفی انجام شد. سیاست‌ها و ارزش‌های واقعی از موتور شطرنج Stockfish بازیابی شدند.



در طول فرآیند آموزش، GNN-graph پایدارترین مسیر یادگیری را نشان داد. نتایج آزمون، عملکرد برتر GNN-graph را نسبت به مدل‌های جایگزین نشان داد.

مقایسه عملکرد آزمون

جدول زیر مقایسه عملکرد آزمون را در مدل‌های GNN-graph، GNN-array و ResNet نشان می‌دهد. GNN-graph در تمام معیارها بهترین عملکرد را دارد.

مدل	MSE	Acc	Best Acc
Resnet	۰.۳۲	۰.۲۷	۰.۱۱
GNN-graph	۰.۲۰	۰.۵۱	۰.۴۲
GNN-array	۰.۲۱	۰.۱۶	۰.۰۷

توضیح معیارها:

- **MSE** (میانگین خطای مربعات): (مقدار کمتر بهتر است) معیاری برای دقت پیش‌بینی ارزش، که نشان می‌دهد مدل چقدر به ارزش واقعی موقعیت نزدیک است
- **Acc** (دقت): کسری از نمونه‌ها که در آن بالاترین حرکت پیش‌بینی شده مدل با هر حرکت غیر صفر در سیاست واقعی مطابقت دارد
- **Best Acc** (بهترین دقت): از سیاست واقعی مطابقت دارد (بالاترین احتمال) کسری از نمونه‌ها که در آن بالاترین پیش‌بینی مدل با بهترین حرکت

مزیت کلیدی: ساختار سیاست مبتنی بر یال

نتایج ما نشان می‌دهد که استراتژی پیشنهادی برای ساخت سیاست، دلیل اصلی عملکرد برتر مدل مبتنی بر GNN نسبت به مدل ResNet است.

نمایش گرافی



خانه‌ها به عنوان گره و حرکات به عنوان یال مدل‌سازی می‌شوند.

جذب روابط



GNN حرکات قانونی را مستقیماً از یال‌ها یاد می‌گیرد.

فضای عملیاتی کاهش یافته



مدل فقط بر روی حرکات قانونی تمرکز می‌کند، نه بر روی فضای عملیاتی کامل ۴۶۷۲ حرکتی.

سیاست برتر



این تمرکز منجر به پیش‌بینی سیاست بسیار دقیق‌تر می‌شود.

این تفاوت در نحوه محاسبه سیاست، مزیت قابل توجهی را برای GNN-graph فراهم می‌کند، زیرا به طور ذاتی ساختار بازی شطرنج را بهتر منعکس می‌کند.



خلاصه GNNs: به عنوان آینده شطرنج AI

این تحقیق نشان می‌دهد که شبکه‌های عصبی گرافی، به ویژه معماری GNN-graph، یک رویکرد برتر برای مدل‌سازی شطرنج نسبت به روش‌های سنتی مبتنی بر آرایه مانند ResNets ارائه می‌دهند.

عملکرد برتر

1. در تمام معیارهای دقت و ارزش بهتر عمل می‌کند GNN-graph

مدل‌سازی رابطه‌ای

2. استفاده از یال‌ها برای سیاست، دینامیک‌های شطرنج را بهتر جذب می‌کند.

کارایی عملیاتی


3. یادگیری بر روی فضای عملیاتی کاهش یافته، کارایی را افزایش می‌دهد.

این یافته‌ها راه را برای استفاده گسترده‌تر از GNNs در هوش مصنوعی بازی‌های تخته‌ای پیچیده هموار می‌کند، جایی که روابط بین عناصر بازی حیاتی هستند.

یافته‌های دیگر و سازگاری

علاوه بر برتری در معیارهای دقت، GNN-graph توانایی‌های عملی دیگری را نیز نشان داد:

تنظیم دقیق (Fine-tuning): فرآیند گرفتن یک مدل از پیش آموزش دیده (مانند GNN-graph و آموزش بیشتر آن با یک مجموعه داده کوچک‌تر و خاص‌تر) مانند سبک بازی یک بازیکن خاص (برای بهبود عملکرد در آن حوزه محدود).



سازگاری با داده‌های کوچک

این مدل با موفقیت خود را با مجموعه داده‌های کوچک و خاص بازیکن از طریق تنظیم دقیق (Fine-tuning) سازگار می‌کند.



برتری در بازی رو در رو

نسبت به مدل‌های دیگر عملکرد بهتری داشت، که نشان‌دهنده (Head-to-head) در بازی‌های رو در رو GNN-graph. قدرت عملی آن است.

منابع کلیدی

- Leela Chess Zero (Pascutto, Linscott)
- Mastering the game of Go without human knowledge (Silver et al.)
- How Attentive are Graph Attention Networks? (Brody, Alon, Yahav)